

Fiche TP - Hadoop, HDFS, YARN et MapReduce

Seance intermediaire avant Apache Spark - 1h30

UTBM

1. Cadre du TP

Vous venez d'étudier une architecture d'intégration avec API REST, broker de messages et traitements asynchrones. Cette architecture produit naturellement des événements, des logs et des traces. Au bout de quelques jours ou quelques mois, ces données deviennent trop volumineuses pour être traitées confortablement sur une seule machine.

Cette séance sert à comprendre le socle historique du traitement Big Data : **HDFS**, **YARN** et **MapReduce**. L'objectif n'est pas d'administrer un cluster Hadoop complet, mais de savoir expliquer ce qui se passe quand on stocke un fichier dans HDFS et quand on lance un job MapReduce sur YARN.

2. Objectifs

À la fin du TP, vous devez savoir :

- distinguer le rôle de HDFS, YARN et MapReduce ;
- charger un fichier local dans HDFS ;
- lancer un job MapReduce WordCount ;
- observer une application YARN ;
- expliquer les phases Map, Shuffle et Reduce ;
- expliquer pourquoi Spark a été créé après MapReduce.

3. Données fournies

Le pack contient trois fichiers dans le dossier `datasets/` :

- `orders.log` : commandes e-commerce simplifiées ;
- `clicks.log` : logs de navigation simplifiées ;
- `catsat.txt` : petit fichier texte pour tester WordCount.

Extrait de `orders.log` :

```
2026-05-01T10:01:22 orderId=01001 channel=web sku=SKU-USB-C qty=2 amount=39.80 status=CREATED
2026-05-01T10:03:11 orderId=01002 channel=mobile sku=SKU-MOUSE qty=1 amount=24.90 status=CREATED
2026-05-01T10:04:08 orderId=01003 channel=web sku=SKU-USB-C qty=1 amount=19.90 status=CANCELLED
```

4. Exercice 1 - vérifier l'environnement

Exécuter les commandes suivantes sur la VM :

```
java -version
hadoop version
hdfs dfs -ls /
yarn node -list
yarn application -list
```

Questions :

1. Hadoop est-il installé ?
2. HDFS répond-il ?
3. YARN voit-il au moins un nœud ?
4. Quelle est la différence entre `hdfs dfs -ls /` et `ls /` ?

5. Exercice 2 - charger les données dans HDFS

Depuis le dossier du pack :

```
./scripts/prepare_hdfs.sh
```

Ou manuellement :

```
hdfs dfs -mkdir -p /shopflow/input
hdfs dfs -put -f datasets/orders.log /shopflow/input/
hdfs dfs -put -f datasets/clicks.log /shopflow/input/
hdfs dfs -put -f datasets/catsat.txt /shopflow/input/
hdfs dfs -ls /shopflow/input
hdfs dfs -cat /shopflow/input/orders.log | head -n 5
hdfs dfs -du -h /shopflow/input
hdfs dfs -count /shopflow/input
```

Questions :

1. Ou se trouve le fichier source avant `hdfs dfs -put` ?
2. Ou se trouve-t-il après `hdfs dfs -put` ?
3. Pourquoi HDFS peut-il stocker un fichier plus gros qu'un seul disque local dans un vrai cluster ?

6. Exercice 3 - lancer un WordCount MapReduce

Lancer WordCount sur `orders.log` :

```
./scripts/run_wordcount.sh /shopflow/input/orders.log /shopflow/output/wordcount_orders
```

Ou manuellement :

```
EXAMPLES_JAR=$(find /usr -name "hadoop-mapreduce-examples*.jar" 2>/dev/null | head -n 1)
echo $EXAMPLES_JAR
hdfs dfs -rm -r -f /shopflow/output/wordcount_orders
hadoop jar "$EXAMPLES_JAR" wordcount /shopflow/input/orders.log /shopflow/output/wordcount_orders
hdfs dfs -cat /shopflow/output/wordcount_orders/part-* | sort
```

Questions :

1. Pourquoi supprime-t-on le dossier de sortie avant de lancer le job ?
2. Ou est écrit le résultat ? Sur le disque local ou dans HDFS ?
3. Pourquoi le résultat peut-il contenir plusieurs fichiers `part-*` ?
4. Reperer dans la sortie le nombre d'occurrences des tokens `channel=web`, `channel=mobile` et `channel=partner`.

7. Exercice 4 - observer YARN

Après exécution du job :

```
yarn application -list -appStates ALL
```

Si l'interface web est active sur la VM, ouvrir :

```
http://localhost:8088
```

Questions :

1. Quel est l'état de l'application MapReduce ?
2. Pourquoi parle-t-on d'application YARN et pas simplement de script local ?
3. Que gère YARN pendant l'exécution ?

8. Exercice 5 - Map / Shuffle / Reduce sur papier

On donne l'entree suivante :

```
order001 web CREATED
order002 mobile CREATED
order003 web CANCELLED
order004 partner CREATED
order005 web CREATED
```

Objectif : compter le nombre de commandes par canal.

A faire :

1. Ecrire la sortie de la phase Map.
2. Ecrire le regroupement de la phase Shuffle.
3. Ecrire le resultat final de la phase Reduce.

Resultat attendu :

```
web 3
mobile 1
partner 1
```

9. Exercice 6 - conclusion comparative

Repondre en 5 a 8 lignes :

Pourquoi Spark est-il plus confortable que MapReduce pour l'analyse de donnees ?

Votre reponse doit utiliser au moins trois des termes suivants :

HDFS, YARN, MapReduce, disque, memoire, DataFrame, SQL, batch, iteration, shuffle

10. Checklist de rendu pour la seance

A rendre ou a conserver dans vos notes :

- une capture de `hdfs dfs -ls /shopflow/input` ;
- une capture du lancement `WordCount` ;
- un extrait du resultat `part-*` ;
- une capture ou sortie de `yarn application -list -appStates ALL` ;
- les reponses aux questions de synthese.

11. Rappel des notions cles

- **HDFS** : systeme de fichiers distribue ;
- **NameNode** : metadonnees, carte des fichiers et blocs ;
- **DataNode** : stockage reel des blocs ;
- **YARN** : gestion des ressources CPU/RAM du cluster ;
- **Container** : enveloppe d'execution avec ressources allouees ;
- **Map** : transformation locale en paires cle/valeur ;
- **Shuffle** : regroupement des valeurs par cle ;
- **Reduce** : consolidation finale par cle.