

Big Data & Neo4j

Examen Blanc

Dr. Mohamed KAS

Partie 1 : Généralités sur le Big Data

Question 1

Quel "V" du Big Data représente le défi lié à l'incertitude, la qualité et la fiabilité des données ?

- A) Volume
- B) Vitesse
- C) Vérité
- D) Variabilité

Réponse :

Question 2

Quel est l'avantage principal d'une architecture "Scale Out" (architecture distribuée) par rapport au "Scale Up" ?

- A) Remplacer un disque dur standard par un disque SSD très performant.
- B) L'ajout horizontal de serveurs standards (Commodity Hardware) peu coûteux pour augmenter la capacité.
- C) Réduire la redondance des données sur le réseau.
- D) Centraliser toute la puissance de calcul sur un seul processeur géant.

Réponse :

Question 3

Dans le contexte du Big Data, qu'est-ce qui caractérise les données dites "semi-structurées" ?

- A) Elles sont stockées uniquement sous forme d'images ou de vidéos brutes.
- B) Elles suivent un schéma relationnel strict (tables, lignes, colonnes).
- C) Elles n'ont pas de schéma fixe relationnel mais possèdent des balises ou marqueurs hiérarchiques (ex: JSON, XML).

D) Elles sont automatiquement chiffrées dès leur création.

Réponse :

Question 4

Quelle est la différence principale entre le traitement de données Batch et le traitement Stream ?

- A) Le Batch traite de grands volumes de données au repos, tandis que le Stream traite les données en mouvement et en temps réel.
- B) Le Batch est réservé aux données non structurées, le Stream aux données structurées.
- C) Le Stream utilise uniquement des disques durs lents, le Batch s'exécute uniquement en mémoire vive.
- D) Il n'y a aucune différence technique, ce sont des termes commerciaux.

Réponse :

Question 5

Quel est le rôle fondamental d'Apache Hadoop dans l'écosystème Big Data ?

- A) Générer des tableaux de bord interactifs en 3D pour la Business Intelligence.
- B) Fournir un framework Open Source de stockage distribué et de traitement parallèle sur des clusters de serveurs standards.
- C) Remplacer intégralement le langage SQL par du code Java.
- D) Assurer la sécurité périmétrique du réseau de l'entreprise.

Réponse :

Partie 2 : Hadoop et HDFS

Question 6

Pourquoi HDFS utilise-t-il une taille de bloc très importante (généralement 128 Mo) comparé aux systèmes de fichiers classiques (ex: NTFS ou ext4) ?

- A) Pour améliorer la qualité des images stockées.
- B) Pour minimiser le coût de recherche sur le disque (seek time) par rapport au temps de transfert effectif des données.
- C) Pour empêcher les petits fichiers d'être sauvegardés.

D) Pour faciliter le chiffrement asymétrique des blocs.

Réponse :

Question 7

Que se passe-t-il si la mémoire vive (RAM) du NameNode est complètement saturée ?

- A) Le NameNode commence à utiliser les disques durs des DataNodes comme RAM virtuelle.
- B) Le cluster HDFS ne peut plus accepter de nouveaux fichiers car l'arbre entier des métadonnées doit tenir en RAM.
- C) Les DataNodes prennent automatiquement le relais pour gérer les métadonnées.
- D) Seuls les fichiers de plus de 1 Go seront refusés.

Réponse :

Question 8

Lors de l'écriture d'un très grand fichier dans HDFS, qui est initialement responsable de diviser ce fichier en blocs de données distincts ?

- A) Le client HDFS (la machine qui envoie les données).
- B) Le NameNode (qui réceptionne le fichier complet d'abord).
- C) L'ApplicationMaster de YARN.
- D) Le premier DataNode du pipeline.

Réponse :

Question 9

Quel est le rôle réel du "Secondary NameNode" dans une architecture HDFS standard (non-HA) ?

- A) Prendre immédiatement le relais (Failover direct) si le NameNode principal tombe en panne.
- B) Servir de cache réseau pour accélérer les téléchargements des clients.
- C) Consolider périodiquement le FSImage et les EditLogs pour éviter que le NameNode ne mette trop de temps à redémarrer.
- D) Exécuter les tâches MapReduce en cas de surcharge du cluster.

Réponse :**Question 10**

Avec un facteur de réplication de 3, comment HDFS réagit-il lorsqu'un DataNode contenant un réplica tombe définitivement en panne ?

- A) Le fichier concerné devient illisible et doit être réimporté par l'utilisateur.
- B) Le NameNode détecte l'absence de "heartbeats" et ordonne la création d'une nouvelle réplique sur un autre nœud sain pour maintenir le facteur à 3.
- C) Le cluster se met en pause et attend qu'un administrateur répare le DataNode.
- D) Le facteur de réplication global du cluster est officiellement abaissé à 2.

Réponse :**Partie 3 : MapReduce et YARN****Question 11**

Dans un job MapReduce standard, que produit exactement l'exécution de la fonction "Map" à partir d'un split de données d'entrée ?

- A) Le fichier final nettoyé et trié dans HDFS.
- B) Un code exécutable Java compilé pour les Reducers.
- C) Une liste de paires (Clé, Valeur) intermédiaires.
- D) Un tableau de bord résumant les données.

Réponse :**Question 12**

Quel est l'objectif principal de la phase "Shuffle and Sort" située entre les Mappers et les Reducers ?

- A) Sécuriser les données en les mélangeant de manière cryptographique.
- B) Regrouper toutes les valeurs associées à une même clé intermédiaire et les acheminer vers le même Reducer.
- C) Réduire la taille des fichiers par compression vidéo.
- D) Choisir aléatoirement quels nœuds vont exécuter le Reduce pour garantir l'équité.

Réponse :**Question 13**

Dans l'architecture YARN, si une application distribuée nécessite des ressources supplémentaires (RAM, vCores), à qui l'ApplicationMaster doit-il en faire la demande ?

- A) Au ResourceManager.
- B) Au NameNode.
- C) Directement à l'utilisateur via une fenêtre pop-up.
- D) À chaque NodeManager individuellement.

Réponse :**Question 14**

Que signifie le concept d'optimisation de "Data Locality" (Localité des données) lors de l'exécution d'un job Hadoop ?

- A) Forcer les utilisateurs à résider dans la même ville que le Data Center.
- B) S'assurer que toutes les données soient sauvegardées sur un seul disque dur local externe.
- C) L'ordonnanceur YARN tente d'exécuter la tâche de calcul (Map) sur le nœud physique qui stocke déjà le bloc de données ciblé sur son disque.
- D) Traduire les données dans la langue locale de l'utilisateur.

Réponse :**Question 15**

Dans YARN, quel composant s'exécute sur chaque machine "Worker" du cluster et a pour mission de superviser les conteneurs locaux (lancer, tuer, surveiller les ressources) ?

- A) Le ResourceManager.
- B) Le NodeManager.
- C) Le JobTracker.
- D) Le Secondary NameNode.

Réponse :

Partie 4 : Hive

Question 16

Pourquoi Apache Hive n'est-il généralement pas adapté pour des applications transactionnelles (OLTP) nécessitant des temps de réponse de l'ordre de la milliseconde ?

- A) Car le langage HQL ne possède pas de clause SELECT.
- B) Car Hive convertit les requêtes en jobs distribués (MapReduce ou Tez) impliquant un temps de latence (overhead) initial d'initialisation très élevé.
- C) Car Hive ne fonctionne que sur le système d'exploitation Windows.
- D) Car les données dans Hive sont toujours effacées après chaque lecture.

Réponse :

Question 17

Où Apache Hive stocke-t-il généralement ses métadonnées (le schéma des tables, les types de colonnes et l'emplacement des fichiers dans HDFS) ?

- A) Dans un "Metastore", très souvent adossé à une base de données relationnelle classique (ex: MySQL ou PostgreSQL).
- B) Directement au début de chaque fichier texte stocké dans HDFS.
- C) Dans le cache L3 du processeur du NameNode.
- D) Hive ne stocke aucune métadonnée, l'utilisateur doit re-déclarer le schéma à chaque requête.

Réponse :

Question 18

Quelle est la conséquence de l'exécution de la commande `DROP TABLE` sur une table Hive qui a été créée avec le mot-clé `EXTERNAL` ?

- A) HDFS est entièrement reformaté.
- B) Les métadonnées et les fichiers HDFS sous-jacents sont définitivement supprimés.
- C) Seules les métadonnées sont supprimées du Metastore ; les données physiques restent parfaitement intactes dans HDFS.
- D) La requête échoue car il est impossible de supprimer une table externe.

Réponse :

Question 19

Quel est l'avantage principal du partitionnement (`PARTITIONED BY`) d'une table Hive lors d'une requête `SELECT` possédant une clause `WHERE` sur cette même clé de partition ?

- A) Le partitionnement chiffre automatiquement les données résultantes.
- B) Hive ignore immédiatement les dossiers HDFS des partitions non pertinentes (Partition Pruning), ce qui réduit drastiquement la quantité de données scannées.
- C) Cela permet d'exécuter la requête sans utiliser le processeur du serveur.
- D) Cela convertit toutes les valeurs textuelles en majuscules pour faciliter la lecture.

Réponse :**Question 20**

Parmi les formats de fichiers supportés par Hive, quel type est spécifiquement optimisé pour les requêtes analytiques qui ne lisent qu'un petit sous-ensemble de colonnes sur une table très large ?

- A) Format brut texte / CSV (Comma Separated Values).
- B) Format séquentiel ligne par ligne (SequenceFile).
- C) Format orienté colonnes tel que ORC ou Parquet.
- D) Format d'image compressée JPEG.

Réponse :

Partie 5 : Neo4j et GraphRAG

Question 21

Dans le modèle de "Graphe de propriétés étiquetés" (Labeled Property Graph) utilisé par Neo4j, qu'est-ce qu'une "Propriété" (Property) ?

- A) Une table relationnelle complète rattachée à un nœud.
- B) Une paire clé-valeur (ex: 'nom: "Alice"') qui peut être stockée soit sur un nœud, soit sur une relation.
- C) Un synonyme pour désigner le pointeur mémoire d'une relation.
- D) La direction obligatoire d'une relation.

Réponse :

Question 22

Que fait exactement la clause Cypher : `MATCH (a:Person) -[:KNOWS]-> (b:Person) ?`

- A) Elle recherche dans le graphe tous les motifs où un nœud de label 'Person' est connecté à un autre nœud 'Person' par une relation de type 'KNOWS', en respectant le sens de la flèche.
- B) Elle supprime tous les nœuds de type 'Person' qui ne se connaissent pas.
- C) Elle crée deux nouvelles personnes nommées 'a' et 'b' et les fait se connaître.
- D) Elle compte le nombre total de relations 'KNOWS' dans toute la base.

Réponse :

Question 23

Quelle caractéristique technique native permet à Neo4j d'être beaucoup plus performant qu'une base relationnelle classique lorsqu'il s'agit de traverser des relations complexes et profondes (similaires à de multiples jointures) ?

- A) L'utilisation exclusive de disques durs magnétiques à bandes.
- B) L'adjacence sans index (Index-free adjacency), où chaque nœud contient des pointeurs physiques directs en mémoire vers ses nœuds voisins.
- C) Le fait que Neo4j ignore les principes ACID pour aller plus vite.
- D) La conversion de toutes les relations en un seul fichier JSON géant.

Réponse :

Question 24

Quel est le principe de base résolvant les hallucinations du LLM dans l'approche "GraphRAG" par rapport au RAG standard ?

- A) Remplacer intégralement le LLM par une simple requête SQL.
- B) Ne plus utiliser de vecteurs mais générer des réponses aléatoires.
- C) Extraire des entités et des relations d'un corpus pour construire un graphe de connaissances, afin d'alimenter le modèle avec un contexte explicite, structuré et connecté.
- D) Traduire le prompt de l'utilisateur en code binaire avant génération.

Réponse :

Question 25

Quel algorithme de la bibliothèque Neo4j GDS (Graph Data Science) utiliseriez-vous pour identifier les personnes considérées comme des "goulets d'étranglement" ou des "ponts" influents dans un réseau (celles qui se trouvent le plus souvent sur le chemin le plus court entre d'autres personnes) ?

- A) Louvain Modularity (Détection de communautés).
- B) Node2Vec (Machine Learning embeddings).
- C) Betweenness Centrality (Centralité d'intermédiation).
- D) Jaccard Similarity (Similarité de nœuds).

Réponse :