



UNIVERSITÉ DE TECHNOLOGIE DE BELFORT-MONTBÉLIARD

LUDS02 : Web stratégies, surveillance, et analyse de données

Un SRI, c'est quoi ?


Questionnement : Comment bien apprivoiser Google et les autres moteurs de recherche ?

UNIVERSITÉ DE TECHNOLOGIE DE BELFORT-MONTBÉLIARD

- Google : 92,37%
- Bing : 3,57%
- Yahoo! : 1,31%
- Yandex : 0,82%
- DuckDuckGo : 0,61%
- Baidu : 0,58%

22 mai 2024


- Optimiser les pages de mon site afin d'acquérir une meilleure visibilité :
 - » Dans les résultats des moteurs de recherche en général et, bien sûr, de Google en particulier.
 - » L'année 2000 a marqué l'engouement pour la création de trafic optimisé pour les sites web avec la première publication de Lary Page et Serge Brin (créateurs de Google).
- Le webmarketing, c'est aussi l'affiliation, les liens sponsorisés, la publicité en ligne et les autres manières de faire connaître son site (ce n'est pas le propos de l'UE !)
- Proposition de l'UE
 - » Référencement naturel (SEO : **S**earch **E**ngine **O**ptimization) :
 - Positionnement,
 - Optimisation de site,
 - Analyse de l'efficacité d'une stratégie de référencement, etc.



UNIVERSITÉ DE TECHNOLOGIE DE BELFORT-MONTBÉLIARD

SEO : définitions et stratégies

- Présentation
- Définitions
- Généralités
- SRI : Systèmes de Recherche d'Informations au sens large
 - » Problématique et objectifs
 - » Processus d'indexation et de recherche
 - » Modèles et approches pour la recherche d'information
 - » Évaluation d'un système d'indexation



Petit historique

- » Le début des années 1990 marque les premiers sites web.
- » Un besoin de **recherche** se fait sentir rapidement avec :
 - L'accroissement exponentiel des sites !
- » L'année 1994 marque l'apparition de l'annuaire Yahoo avec une notion de catalogue sous forme de catégories et sous catégories façon bibliothéconomie !
 - Puis, l'Open Directory ou Dmoz, en France le Guide de Voilà, Nomade etc.
- » Aussi, les moteurs qui recensent de façon plus granulaire des pages web :
 - Webcrawler, Excite, Lycos, Infoseek,
 - Puis, un peu plus tard, Altavista, Google, etc.
 - Une apparition par la suite des métamoteurs qui combinent et comparent plusieurs moteurs comme « dogpile et metacrawler »
 - L'utilisation en force de la **puissance de Google**

- Aujourd'hui, dans l'univers « Big Data »: Une complexité algorithmique croissante !
 - » Google et Bing sont extrêmement complexes et à base d'intelligence artificielle, d'apprentissage automatique et de réseaux de neurones.
 - » Un fonctionnement devenu de plus en plus difficile d'où le métier de référenceur !
 - » Le fil conducteur de ce cours.

■ Référencement

- » Lorsque votre site sera « présent » dans les bases de données « index » d'un moteur, on dira qu'il est « référencé » ou « indexé ».
 - Se promener dans les rayons d'un magasin et voir un certain nombre de produits. On dit dans le jargon commercial, que ces produits sont « **référéncés** » auprès de la grande surface :
 - Donc présents, stockés, et « **trouvables** ».
 - Mais ! Sont-ils placés parmi tant d'autres de la même façon dans de nombreux rayons ?
- » C'est une première étape, **nécessaire** mais **pas suffisante**, dans le processus de gain de visibilité de votre source d'information. Un vrai travail d'optimisation vous attend pour gagner en visibilité. (Le positionnement !)

■ Positionnement

- » Une phase tout aussi importante pour mettre votre site en « tête de gondole », en le positionnant au mieux dans les résultats de recherche des mots-clés les plus importants pour votre activité.
- » On parle de **SEO** (Search Engine Optimization) : optimisation pour les moteurs de recherche / référencement naturel.
- » Mais on parle aussi de **SEA** (Search Engine Advertising) : un référencement payant !

■ Liens organiques

- » Ou liens « naturels » : aucun processus publicitaire ou financier n'intervient dans leur classement.
- » Les résultats affichés par le moteur de recherche (sans publicité), la plupart du temps sous la forme d'une dizaine de liens représentés chacun par :
 - un titre,
 - un descriptif,
 - une URL.
- » On les appelle également parfois (notamment chez Microsoft/Bing) les « liens bleus ».

■ Liens sponsorisés

- » La visibilité est monnayée !

■ SEM (Search Engine Marketing)


- » Une stratégie de visibilité sur les moteurs de recherche
- » SEM = SEO + SEA

Une représentation schématique autour d'un SRI

UNIVERSITÉ DE TECHNOLOGIE DE BELFORT-MONTBÉLIARD


Trois modèles le composent :

- » Modèle de documents
- » Modèle de requête
- » Fonction de correspondance : Le Matching entre la « requête » et un ensemble de « documents »



Une forme d'indexation encore pratiquée (exemple de l'INA (Institut National de l'Audiovisuel)) :

- » Le rôle de l'indexeur est d'attribuer au document à archiver un certain nombre de descripteurs :



Mots-clés unitermes

- » Descripteurs formés d'un seul mot. Par conjonction de plusieurs unitermes, on obtient des expressions composées.

■ Descripteurs composés :

- » Constitués d'expressions de deux ou trois termes.
- » On peut utiliser des expressions de différents types :
 - nom-adjectif, comme
 - Droit social
 - nom-complément du nom, comme
 - Histoire de la musique
 - les termes possédant un trait d'union,
 - Libre-échange
 - des termes avec rejet, comme
 - Boole, algèbre de
 - Bien adaptées pour les catalogues manuels
 - des termes avec un qualificatif, comme
 - Mercure (métal), Mercure (planète)

■ Descripteurs structurés

- » Un descripteur structuré contient plusieurs informations sous une même entrée dite "vedette".
- » On fait succéder les descripteurs dans l'ordre suivant :
 - tête de vedette, significative du sujet
 - sous-vedette de point de vue
 - sous-vedette de localisation géographique
 - sous-vedette de localisation chronologique
 - sous-vedette de forme (dictionnaire, bibliographie, congrès)
- » Exemple, le format UNIMARC
 - UNIMARC signifie « UNIversal Machine Readable Cataloguing
 - C'est un format permettant, sous forme informatisée, le catalogage manuel, le traitement et l'échange de données bibliographiques.
 - Développé et est maintenu par l'IFLA, la Fédération internationale des associations et institutions de bibliothèques.

■ Indices de classification

La classification permet de situer un document dans un système de domaine de connaissances :

Les classifications hiérarchiques :


5 Science

51 Mathématique

512 Algèbre

513 Arithmétique

Les classes de la Dewey



La classification **Dewey** est un système de rangement universel utilisé par les bibliothèques du monde entier pour organiser leurs collections. Basé sur un indice décimal, il divise les connaissances humaines en classes principales, facilitant ainsi la recherche d'ouvrages

■ Indexation par des méthodes sémantiques

- Relations sémantiques entre termes.
- Représenter le document dans un langage de description tenant compte des relations sémantiques.
- Extension de la notion de thesaurus.

■ Méthodes linguistiques

- Analyse plus profonde : plusieurs types de traitements.
- Avantage
 - analyse fine des unités de sens du texte
- Inconvénients (qui se font **moins sentir** de nos jours avec l'IA!)
 - nécessité d'un dictionnaire complet
 - fonctions d'analyse linguistique lourdes et coûteuses

■ Méthodes statistiques

- basées sur le calcul de fréquences de termes

■ Indexation orientée document

- » L'objectif est de résumer ou de présenter le contenu de chaque document.

■ Indexation orientée requête

- » Pour chaque document, refléter les requêtes pour lesquelles il est pertinent : l'indexation d'un document doit alors représenter les raisons pour lesquelles un utilisateur consulte ce document (i.e. : confronter chaque document de la base à une liste de requêtes prédéfinies)

Quelle indexation choisir ?

■ **Les indexations proposées dans les systèmes de recherche d'informations doivent être mixtes. En effet, les besoins des systèmes sont doubles :**

» Afin de servir le spectre le **plus large d'utilisateurs**, le système doit disposer du maximum d'informations sur les documents. De ce point de vue, l'indexation doit donc être **orientée document**.

» Exemple : Un site internet

» Afin de servir au mieux **un utilisateur**, de ce point de vue, l'indexation doit être **orientée requête**.

» Exemple : Un intranet

Vocabulaire d'indexation

- » **Les langages libres**, ou **non contrôlés** : langages évolutifs car ils sont constitués « a posteriori » sur la base de l'indexation en langage naturel des documents déjà enregistrés dans une collection.
- » **Les langages contrôlés** : langages figés car construits « a priori » avant de commencer à indexer des documents d'une collection. Ces langages éliminent tout nouveau mot ou concept.
 - » Utilisation de thésaurus

- Pré-coordination ou post-coordination du langage d'indexation
 - » Pré-coordination : Coordination « **a priori** » des termes qui sont reliés entre eux (**avant l'interrogation**).
 - » Post-coordination : Coordination « **a posteriori** » des termes qui sont reliés entre eux (**au moment de l'interrogation**).

■ Le modèle booléen

- » L'exemple du premier modèle de la base MEDLINE, base de données internationale en sciences de la santé et sciences biomédicales.
- » Ce modèle représente les documents et les requêtes sous forme d'une proposition de termes et d'opérateurs logiques, et fournit une fonction de correspondance basée sur l'implication $D=Q$
- » Une requête est une expression logique composée de termes connectés par les **opérateurs logiques** $\wedge, \vee$ et $\neg$
- » Simplicité, bonnes performances quantitatives, même sur de très grandes collections de documents.
- » Mais ! limitations sur le plan qualitatif (**évaluation binaire**)

■ Le modèle probabiliste

- » Mesure la probabilité de pertinence d'un document par rapport à une requête
- » Utilise 2 probabilités pour chaque document :
 - » La probabilité de pertinence du document D, $P(\text{per}/D)$,
 - » La probabilité de non-pertinence du document D, $P(\text{nonper}/D)$
- » La fonction de recherche $g(D)$ donne un ordonnancement des documents :
 - » $g(D) = (P(\text{per}/D)/P(\text{nonper}/D))$
- » Probabilités calculées en fonction des termes d'indexation de la base.

■ Le modèle vectoriel (SMART[Salton 83])

- » Un document D_i est représenté par un vecteur de termes d'indexation. $D_i = (W_{i1}, \dots, W_{ij}, \dots, W_{in})$ où n représente le nombre de termes d'indexation et W_{ij} la pondération du terme t_j dans le document D_i .
- » $W_{ij} = \text{FLOC}_{ij} / \text{FDOC}_j$, où
- » FLOC_{ij} : Fréquence locale de t_j dans le document D_i ,
- » FDOC_j : Fréquence documentaire de t_j dans tout le corpus .
- » Vecteur requête $Q = (k_1, \dots, k_j, \dots, K_n)$
- » Similarité $(D_i, Q) = (\sum_j W_{ij} k_j / (\sum_j W_{ij}^2 \sum_j K_j^2)^{1/2}$

- **Précision relative**
 - Nombre de documents trouvés jugés pertinents par l'utilisateur
- **Rappel relatif**
 - Proportion de documents trouvés jugés pertinents par rapport au nombre global de documents pertinents
- **Digression**
 - Nombre de documents trouvés et jugés non pertinents
- **Silence**
 - Nombre de documents jugés pertinents et non retrouvés

Bouclage de pertinence

UNIVERSITÉ DE TECHNOLOGIE DE BELFORT-MONTBÉLIARD

$$\text{Gain de bouclage} = \frac{|Pertinent_{u,i} \cap Trouvés_i|}{|\bigcup_{j=1}^i Pertinents_{u,j} \cap Trouvés_j|}$$

$$\text{Perte de bouclage} = \frac{|NonPertinent_{u,i} \cap Trouvés_i|}{|\bigcup_{j=1}^i NonPertinents_{u,j} \cap Trouvés_j|}$$


Gain de bouclage désigne le nombre de nouveaux documents retrouvés à l'étape i et jugés pertinents par l'utilisateur.

Perte de bouclage désigne le nombre de nouveaux documents retrouvés à l'étape i et jugés non pertinents par l'utilisateur.



UNIVERSITÉ DE TECHNOLOGIE DE BELFORT-MONTBÉLIARD

Merci



>> www.utbm.fr

Suivez toute l'actu de l'UTBM sur :

