



UNIVERSITÉ DE TECHNOLOGIE DE BELFORT-MONTBÉLIARD

LUDS02 : Web stratégies, surveillance, et analyse de données

SRI, côté Web : Google

L'aventure de Larry Page et Serge Brin

UNIVERSITÉ DE TECHNOLOGIE DE BELFORT-MONTBÉLIARD

- Larry Page et Sergey Brin, deux étudiants provenant respectivement des facultés de Mathématique et d'Informatique de l'Université de Stamford.
- Ils conçoivent et gèrent un projet de recherche qui mène à la création de Google.
- Les années 1999-2000 marquent les premiers succès



Origine du nom Google



UNIVERSITÉ DE TECHNOLOGIE DE BELFORT-MONTBÉLIARD

- Inspiré du terme mathématique anglais googol, « gogol» en français
- Désigne le nombre 10 puissance 100 :
 - » Mot apparu en 1938 dans le livre d'Edward Kasner et James H. Newman, *mathematics and Imagination* (les mathématiques et l'imagination)
 - » Kasner a choisi le mot **gogol** (donné par son neveu Milton Sirota : 9 ans) pour illustrer le fait qu'**un nombre aussi grand soit-il, reste toujours éloigné de l'infini**
- Pour Page et Brin
 - » Le nom google, comme référence au googol, reflète la mission du moteur de recherche.
 - » Organiser l'immense volume d'information sur le web

La base de l'algorithme de classement

UNIVERSITÉ DE TECHNOLOGIE DE BELFORT-MONTBÉLIARD

- 2 types de pages :
 - les pages de références
(i.e. pages fréquemment citées)
 - les pages pivots
(i.e. pages contenant un grand nombre de liens)



- Définition récursive de l'importance des pages
 - « plus une page de référence est pointée par de bonnes pages pivots, plus elle sera une bonne page de référence »
 - « plus une page pivot pointera de bonnes pages de références, plus elle sera une bonne page pivot »

Dans la pratique, comment ça marche ?

UNIVERSITÉ DE TECHNOLOGIE DE BELFORT-MONTBÉLIARD

- *La formule proposée [Brin, 1998] tient compte de la probabilité de suivre effectivement les liens*
- *La probabilité d'arriver à la page P sans suivre de lien est donc de $(1-d)$.*
 - » *Avec d étant le facteur d'amortissement*
 - » *$0 < d < 1$*
- *$PR(P)$: PageRank de la page P*
- *$PR(P) = (1-d) + d [(PR(P1)/C(P1) + \dots + (PR(Pm)/C(Pm))]$*
 - *$C(Pj)$ = nombre de liens sortant de la page P*

Exemple (suivre le déroulement au tableau)

UNIVERSITÉ DE TECHNOLOGIE DE BELFORT-MONTBÉLIARD

$$PR(P) = (1-d) + d [(PR(P1)/C(P1) + \dots + (PR(Pm)/C(Pm))]$$

– L'algorithme du PageRank expliqué avec quatre pages liées et un facteur

d'amortissement $d = 0.85$

– Il n'y a pas de lien(s) entrant(s) sur la page D. Son PR sera donc toujours de 0.15 du fait au premier terme de la formule du PageRank $(1-d)$ qui correspond à la probabilité d'arriver sur D sans suivre les liens.

– Bien qu'ayant un PR calculé, il est vraisemblable que cette page disparaîtra de l'index Google très vite, n'ayant aucun lien entrant !


– Au bout d'une vingtaine d'itérations, les valeurs de PR pour nos pages convergent vers les valeurs suivantes :

Page A 1.49

Page B 0.78

Page C 1.58

Page D 0.15



■ Algorithme de classement

- » Évaluation de chaque page par rapport à :
 - un score de référence
 - un score pivot

■ Méthode de calcul des scores

- » Augmentation des valeurs des pages pivots par rapport aux meilleurs pages de référence
- » Augmentation des valeurs des pages de référence par rapport aux bonnes pages pivots

■ Après quelques itérations, le classement devient stationnaire

Google bombing (le bombardement google)

UNIVERSITÉ DE TECHNOLOGIE DE BELFORT-MONTBÉLIARD


- Détournement de la façon dont Google évalue la pertinence d'un site :
 - Si de nombreux liens qui pointent vers un site utilisent une même expression, celle-ci a toutes les chances, tapée dans Google, d'être associée au site ciblé.
- Inspire les plaisantins qui veulent ressortir des pages en tapant des expressions :
 - Création de fausses pages qui pointent vers le site ciblé
 - Exemple des plus célèbres, rechercher « miserable failure » (traduction : « pauvre crétin ») qui renvoi vers le site de la maison blanche, alors occupé par G. W. Bush.

■ Des failles sans cesse détectées et corrigées par les moteurs...



UNIVERSITÉ DE TECHNOLOGIE DE BELFORT-MONTBÉLIARD

Merci



>> www.utbm.fr

Suivez toute l'actu de l'UTBM sur :

