

Fiche de révision — Web stratégie, surveillance & analyse de données

1. Le SRI (Système de Recherche d'Information)

Définition : système qui indexe et restitue des documents (pages web) pertinents face à une requête. But du cours : comprendre comment optimiser un site pour gagner en **visibilité** dans les moteurs (Google ≈ acteur dominant).

Repères historiques :

- Années 1990 : premiers sites web, besoin de recherche.
- 1994 : annuaire **Yahoo** (catalogue par catégories, logique bibliothéconomie). Puis Dmoz / Open Directory.
- Moteurs granulaires : Webcrawler, Excite, Lycos, Altavista...
- 2000 : 1^{re} publication de **Larry Page & Sergey Brin** → Google.
- Aujourd'hui (Big Data) : algos très complexes basés sur IA, machine learning, réseaux de neurones → d'où le métier de **référéncieur**.

2. Vocabulaire clé

Référencement vs Positionnement

- **Référencement (indexation)** : le site est *présent* dans l'index du moteur. Nécessaire mais **pas suffisant**.
- **Positionnement** : placer le site en « tête de gondole », bien classé sur les mots-clés stratégiques. C'est le vrai travail d'optimisation.

SEO · SEA · SEM

Sigle	Signification
SEO	Search Engine Optimization = référencement naturel (gratuit, organique)
SEA	Search Engine Advertising = référencement payant (liens sponsorisés)
SEM	Search Engine Marketing = stratégie globale. SEM = SEO + SEA

Types de liens

- **Liens organiques / naturels** : aucun processus payant. Affichés sous forme de titre + descriptif + URL (les « liens bleus » chez Bing).
- **Liens sponsorisés** : la visibilité est **monnayée**.

3. Processus d'un moteur

- 2 grandes phases :**
- ① **Indexation** (en amont) : crawl des pages → analyse du contenu → stockage dans l'index.
 - ② **Recherche** (à la requête) : appariement requête ↔ documents indexés → classement (ranking) → résultats.

Évaluation d'un système d'indexation se mesure classiquement par la **précision** (pertinence des résultats retournés) et le **rappel** (capacité à retrouver tous les documents pertinents).

4. À retenir pour l'exam

CLÉ Le SEO ne se limite pas à « être indexé » : l'objectif est le **positionnement**. SEM = SEO + SEA. Google s'appuie historiquement sur le **PageRank** (voir page 2) pour classer les pages.

1. Idée fondatrice

Une page est **importante** si beaucoup de pages importantes pointent vers elle. La **notoriété** se transmet par les **liens entrants**. Modèle du « surfeur aléatoire » : un internaute suit les liens au hasard.

2. La formule

$$PR(P) = (1 - d) + d \times [PR(P_1)/C(P_1) + \dots + PR(P_m)/C(P_m)]$$

- **PR(P)** : PageRank de la page P.
- **d** : facteur d'amortissement (damping), $0 < d < 1$, en pratique **d = 0,85**.
- **(1 - d)** : probabilité d'arriver sur P *sans* suivre de lien (= 0,15).
- **P_i** : pages qui pointent vers P (liens entrants).
- **C(P_i)** : nombre de liens **sortants** de P_i → la notoriété d'une page se **divise** entre toutes ses cibles.

3. Exemple du cours (4 pages, d = 0,85)

Initialisation : PR équiprobable = 1/4 pour A, B, C, D.

Itération 1 (extraits du calcul) :

- $PR(A) = 0,15 + 0,85 \times (1/4) = \mathbf{0,3625}$
- $PR(B) = 0,15 + 0,85 \times (1/8) = \mathbf{0,25625}$ (A référence 2 pages → 1/4÷2)
- $PR(C) = 0,15 + 0,85 \times (1/8 + 1/4 + 1/4) = \mathbf{0,68125}$

• $PR(D) = 0,15 + 0,85 \times 0 = \mathbf{0,15}$

Cas de D : aucun lien entrant → PR reste bloqué à **0,15** (juste le terme 1-d). La page risque de **disparaître de l'index**. ⇒ il faut chercher des **liens entrants** (réseaux sociaux, autres sites) sinon on reste « dans l'ombre ».

Convergence (après ~20 itérations)

Page	A	B	C	D
PR final	1,49	0,78	1,58	0,15

Le classement devient **stationnaire** : les valeurs ne bougent plus après quelques itérations (méthode itérative).

4. Notions associées

- **Google bombing** : manipulation du classement en créant massivement des liens avec un même texte d'ancre → faille détectée et corrigée par les moteurs.
- **Origine du nom Google** : du terme math *googol* = 10¹⁰⁰, illustrant le volume immense d'information à organiser.

CLÉ EXAM Savoir **appliquer la formule sur 1 itération** : bien identifier les liens entrants de chaque page et diviser par le nombre de liens **sortants** de la page source. Une page sans lien entrant = PR figé à (1-d).

1. GA4 & GTM

GA4 (Google Analytics 4) repose **entièrement sur une logique événementielle** : tout comportement = un événement (même une page vue). **GTM** (Google Tag Manager) = gestion **centralisée des balises** (tags) sans toucher au code ; structure et déploie les événements. GTM est **gratuit**.

Structure d'un événement

- **Nom** : `page_view` `login` `add_to_cart` `purchase`
- **Paramètres** (contexte) : `button_text`, `value`, `item_id`, `page_location`...
- **Propriétés utilisateur** (`user_properties`) : langue, type d'abonné, pays — *sans* identifier la personne.

4 familles d'événements

Famille	Exemples
Automatiques	<code>page_view</code> , <code>scroll</code> , <code>session_start</code>
Recommandés	<code>login</code> , <code>sign_up</code> , <code>add_to_cart</code> , <code>purchase</code>
Personnalisés	<code>cta_click</code> , <code>video_progress</code> , <code>download_pdf</code>
Conversions	objectif stratégique : formulaire, achat, clic clé

Plan de marquage

Document listant **précisément ce qui doit être mesuré** (événements, paramètres, objectifs) ; base commune marketing / data / dev. **Étapes** : ① objectifs business → ② cartographier parcours → ③ identifier événements → ④ définir paramètres → ⑤ structurer le doc → ⑥ implémenter (GTM, **DataLayer**).

DataLayer : couche qui stocke temporairement les infos clés transmises à GTM.

2. A/B testing

Comparer 2 variantes (A vs B) d'un élément (bouton, titre...) sur des groupes de trafic répartis aléatoirement, pour décider laquelle convertit le mieux. Outil vu en TP : **GrowthBook**.

Démarche : définir métriques & audiences → créer l'expérience & ses variantes → répartir le trafic → collecter → analyser (p-value, intervalle de confiance) → décider. **Bonnes pratiques** : taille d'échantillon suffisante, durée suffisante, seuil statistique fixé à l'avance, attention aux biais.

Le test A/A (calcul type)

Deux groupes voient la **même** version A → sert à valider que la répartition est bien aléatoire et sans biais. Test de différence de proportions :

	A1	A2
Visiteurs	1000	1000
Conversions	120 (12 %)	115 (11,5 %)

$p = (120+115)/2000 = \mathbf{0,1175}$
 $SE = \sqrt{p(1-p)(1/n_1 + 1/n_2)} \approx \mathbf{0,0144}$
 $z = (p_1 - p_2)/SE = (0,12-0,115)/0,0144 \approx \mathbf{0,347}$
→ p-value $\approx \mathbf{0,73}$ ($\gg 0,05$)

Conclusion : écart **non significatif** (dû au hasard) — résultat attendu pour un A/A.

RÈGLE p-value < 0,05 ⇒ différence **significative**. p-value ≥ 0,05 ⇒ on ne peut pas conclure à un effet réel.

1. Qualité du contenu — Google Panda

Panda (2011) **dévalue** les sites à contenu de faible qualité, texte insuffisant ou **duplicate content**. Objectif : récompenser le contenu **utile, unique, ciblé**.

Grille de notation (/10 par critère)

- **Qualité** du contenu (richesse, profondeur, originalité)
- **Lisibilité** (clarté, structure des phrases)
- **Valeur utilisateur** (utilité réelle)
- **Structure SEO** (H1, H2, paragraphes)

Note = (Qualité + Lisibilité + Valeur + Structure) / 4
Pondérée : 0,4·Qualité + 0,2·Lisibilité + 0,3·Valeur + 0,1·Structure

Outils d'appui : SEMrush/Surfer (contenu), Yoast/Hemingway (lisibilité), 1.fr (sémantique), Screaming Frog (structure). Approche **hybride** : outils + jugement humain.

Optimisation sémantique (IA)

Outils type **YourTextGuru** / 1.fr / Ubersuggest : guides SEO, **mots-clés** à placer dans Title/H1/H2/méta, **entités nommées** (personnes, lieux, organisations issues de Wikipédia) pour lever l'ambiguïté (ex. « avocat » fruit vs profession) et renforcer la pertinence.

2. Stratégie éditoriale web

- Information **orientée utilisateur** et **utile** : parler des besoins du public, pas de soi. Lutter contre l'**infobésité** (écologie éditoriale).
- **Positionnement éditorial** : identité, proposition de valeur, **parler le langage du client**, territoire & angle éditorial, tonalité de marque.
- **Buyer personas** : profils de clients types → calendrier de contenus adapté.

Bonnes pratiques de rédaction web

- **Lecture en balayage** (3 niveaux) : ① évaluation (survol : titres, photos) → ② confirmation (promesse tenue ?) → ③ profondeur (**seuls ~15 %** lisent en entier).
- Stats : **20–28 %** du texte lu ; intro = **4–7 s** pour convaincre ; titres lus **5x** plus ; **3x** plus d'accroches lues que d'articles.
- **Concision** (Luc Fayard) : > 13 mots/phrasedépense. 1 phrase = 1 info ; 1 idée = 1 paragraphe ; alterner phrases longues/courtes.
- **QQOQCP / 5W** : Qui, Quoi, Où, Quand, Pourquoi (+ Combien, Comment).

3. Analyse qualimétrique

Qualité = concept **multidimensionnel et subjectif** (performance, fiabilité, ergonomie, sécurité, satisfaction...). Démarche hiérarchique en 3 niveaux :

Niveau	Définition	Exemple
Facteur	Caractéristique générale, abstraite, non mesurable directement	Engagement, Conversion, Ergonomie
Critère	Exigence concrète issue du facteur	Améliorer l'UX ; optimiser les landing pages
Métrique	Mesure quantitative, objective	↓ taux de rebond, ↑ durée de session, taux de conversion

Restitution : **tableau de bord type BI** regroupant les métriques clés (KPI : conversions, valeur, churn, engagement).

CLÉ EXAM Sache distinguer **Facteur** → **Critère** → **Métrique** (du plus abstrait au plus mesurable) et donner un exemple complet pour une stratégie web.