

Recherche d'informations WEB

Algorithme de PageRank :

Tout le monde connaît l'extraordinaire aventure de Larry Page et Sergey Brin, deux étudiants provenant respectivement des facultés de Mathématique et d'Informatique de l'Université de Stanford. Ils conçoivent et gèrent un projet de recherche qui mène à la création de Google. Les années 1999-2000 marquent les premiers succès. America On Line, avec 34 millions de clients et 10 millions de visiteurs par jour, signe un accord qui le lie à la technologie Google. Aujourd'hui, Google est synonyme de la recherche sur Internet, avec un index de l'ordre de milliards de pages.

L'approche de Brin et Page est basée sur la notion de propagation de popularité. *Le principe est d'évaluer l'importance d'une page en fonction de chaque page pointant vers elle. La propagation met en avant les pages qui jouent un rôle particulier dans le réseau des liens, avec l'hypothèse : **une page référencée par un grand nombre de pages est une bonne page.** Cette mesure est une distribution de probabilité sur les pages. Elle mesure en fait la probabilité PR pour un internaute naviguant au hasard, d'atteindre une page donnée P. Cette probabilité est d'autant plus forte que le nombre de pages qui réfèrent P est important. PR est donc fonction de la somme des probabilités des pages qui réfèrent P. Il faut aussi tenir compte du fait que les pages qui réfèrent P ont d'autres liens sortant vers d'autres pages que P. Il faut alors diviser cette probabilité par le nombre C de liens sortant des pages qui réfèrent P. Finalement, il faut tenir compte du fait qu'un internaute peut arriver sur une page quelconque sans suivre de liens (à partir de ses signets par exemple). La formule proposée [Brin, 1998] tient ainsi compte de la probabilité de suivre effectivement les liens. La probabilité d'arriver à la page P sans suivre de lien est donc de (1-d). La formule de calcul du PageRank est alors la suivante :*

$$PR(P) = (1-d) + d [(PR(P_1)/C(P_1) + \dots + (PR(P_m)/C(P_m))]$$


Avec d, facteur d'amortissement $0 < d < 1$ (probabilité d'arriver à la page P en suivant effectivement les liens)

$C(P_j)$ = nombre de liens sortant de la page P

$PR(P)$: PageRank de la page P

Dans la pratique, comment ça marche?

Prenons un exemple, *l'algorithme du PageRank expliqué* avec quatre pages liées et un facteur d'amortissement de 0.85 :




Dans cet exemple nous avons un site contenant quatre pages, dont une ne recevant aucun lien (la page D). Le PR de la page D sera donc de 0.15, grâce au premier terme de la formule du PageRank $(1-d)$. Bien qu'ayant un PR calculé, il est vraisemblable que cette page disparaîtra de l'index Google très vite, n'ayant aucun lien entrant. Au bout d'une vingtaine d'itérations, les valeurs de PR pour nos pages convergent vers les valeurs suivantes :

Page A	1.49
Page B	0.78
Page C	1.58
Page D	0.15
Somme des PageRank	4.0
Moyenne	1.0

Nous voyons que dans notre exemple, la page C a le PR le plus élevé. C'était prévisible dès l'examen du graphique, elle reçoit un lien entrant des pages A, B et D, et n'en émet qu'un seul vers la page A.

Exercice 1 :

Considérons le cas de figure simplifié d'un ensemble de six documents, les pivots et les références sont données comme sur la figure suivante :



On considère qu'à l'état initial, toutes les pages sont équiprobables et le facteur d'amortissement = 0,8

Calculer la valeur du PageRank à l'étape 3 (3^{ème} itération) du nœud D ? Quelles sont vos remarques ?