

TD : Indexation textuelle, SRI (systèmes de recherche d'informations)

Soit le tableau suivant donnant les fréquences locales des termes t_j dans le corpus de documents D_i :

	D1	D2	D3	D4	D5	D6	D7	D8	D9	D10
cigarette	12	8	0	0	0	0	0	0	16	4
tabagisme	8	4	0	0	0	0	0	0	4	4
hypertension	9	0	0	0	0	0	0	3	3	0
artérite	6	10	0	0	0	0	0	0	0	0
traitement	20	10	10	20	30	10	10	20	20	10
myocarde	6	3	0	0	0	0	0	0	9	0
sevrage	0	4	0	0	0	0	0	0	6	0
homme	0	8	0	0	12	0	8	0	4	0
femme	0	12	0	0	4	0	4	0	4	0
cancer	0	10	5	0	10	0	5	0	5	0

Suite aux requêtes données ci-dessous, donner la liste des documents retournés par **ordre décroissant de pertinence** (quand il existe : selon le modèle de SRI).

1°) Modèle booléen

- cigarette $\wedge$ cancer
- (cancer $\wedge$ traitement) $\wedge$ ($\neg$ (cigarette $\vee$ tabagisme))
- cigarette $\vee$ tabagisme $\vee$ hypertension $\vee$ $\neg$ cancer

2°) Modèle vectoriel (selon SALTON)

- cancer chez la femme
- tabagisme et sevrage

Rappel :

Le modèle vectoriel (SMART[Salton])

- Un document D_i est représenté par un vecteur de *termes d'indexation*. $D_i = (W_{i1}, \dots, W_{ij}, \dots, W_{in})$ où n représente le nombre de termes d'indexation et W_{ij} la pondération du terme t_j dans le document D_i .
- $W_{ij} = FLOC_{ij} / FDOC_j$, où
 $FLOC_{ij}$: Fréquence locale de t_j dans le document D_i ,
 $FDOC_j$: Fréquence documentaire de t_j dans tout le corpus.
- Vecteur requête $Q = (k_1, \dots, k_j, \dots, k_n)$
- Similarité $(D_i, Q) = (\sum_j W_{ij} k_j / (\sum_j W_{ij}^2 \sum_j k_j^2)^{1/2})$